Kettle 入门级介绍

> kettle 中文网

安装 kettle

去 kettle 中文网 下载 kettle 软件（他的官网经常崩溃，估计是没钱不维护了），下载完的解压包解压后，会发现里面有 `*.bat,*.sh` 脚本文件，你会发现，这是一个 `windows` 与 `linux` 通用的安装包

解压完后，我们点击 `Spoon.bat` 就可以在 `windows` 下启动 kettle 了，推荐大家是先在 `windows` 下配置好任务后再上传到 `linux` 中，利用 `linux` 的定时任务去执行

创建转换任务

打开了 `kettle` 后，进入的页面是这样的

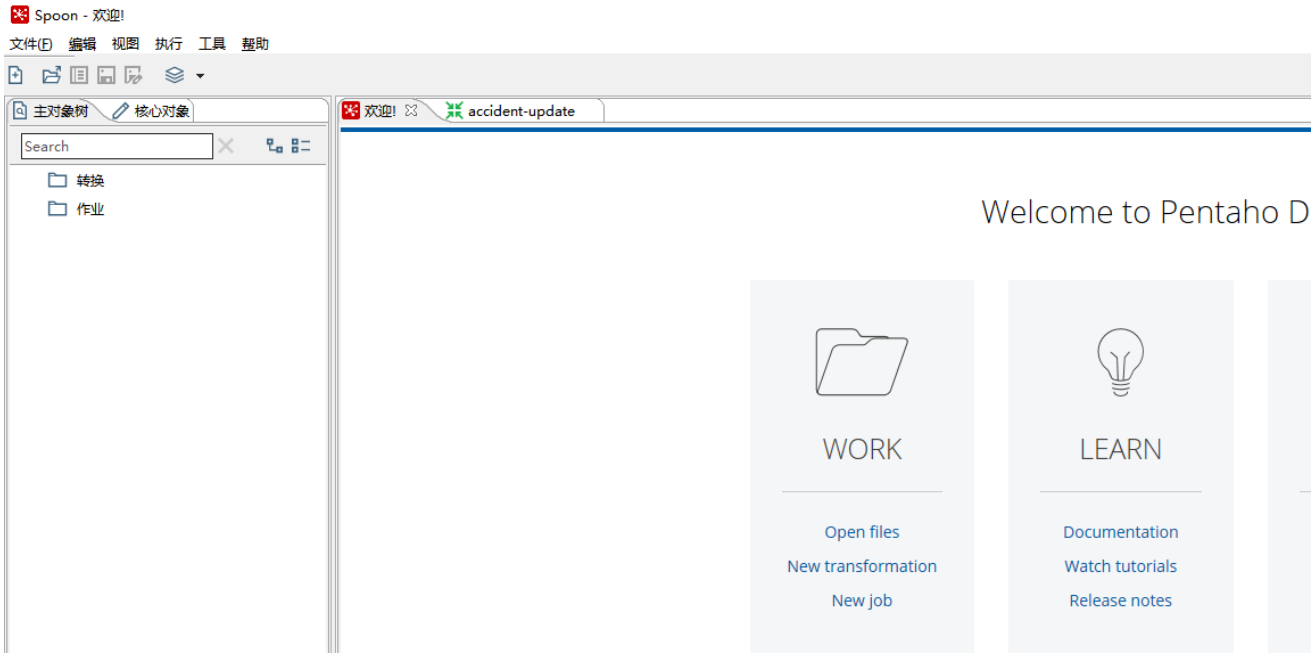

在左边的主对象树中，有两个对象，一个是转换，一个是作业，简单介绍一下，转换就是创建转换任务，作业呢就是在转换任务创建好后设置工作流之类的（例如定时器），我们在这里不需要用他的作业，所以只需要创建转换就好了，定时任务交给 `linux` 来做。

右键创建一个转换，创建完毕后会自动跳转到 `核心对象` ，没有自动跳就自己点过去

添加数据库连接

`kettle` 获取数据与输出方式由多种，我们可以点击转换下拉框查看一下

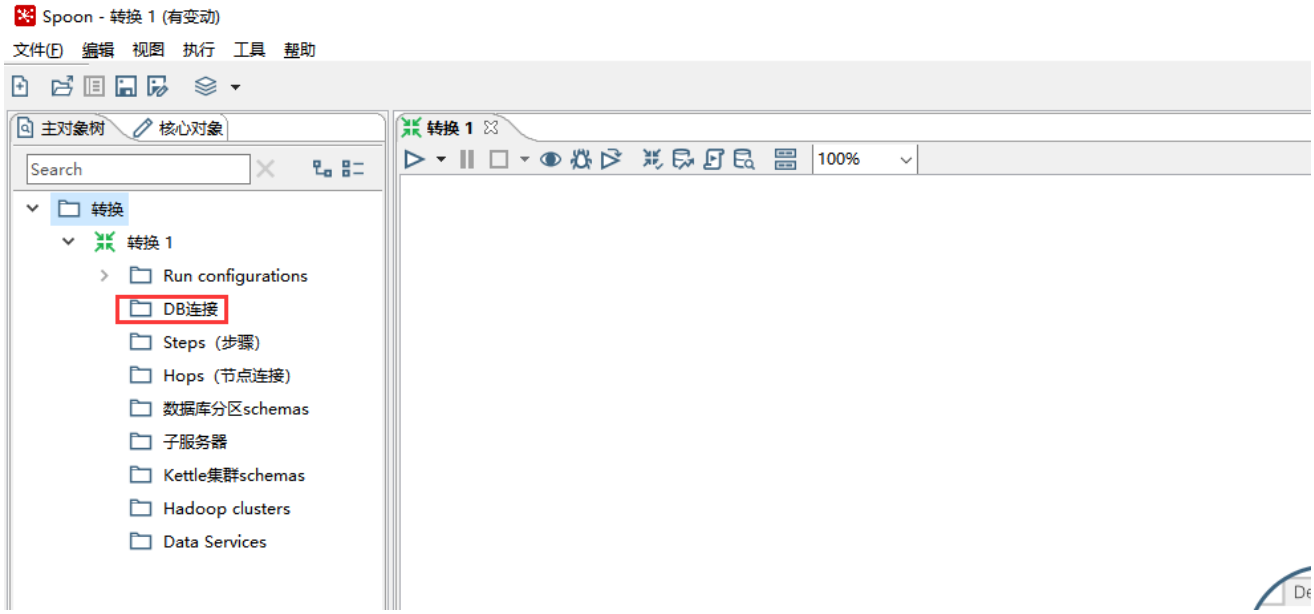

一般的转换都是从这个库到那个库的，所以我们需要创建两个 `DB连接` ，我们双击它来看一哈

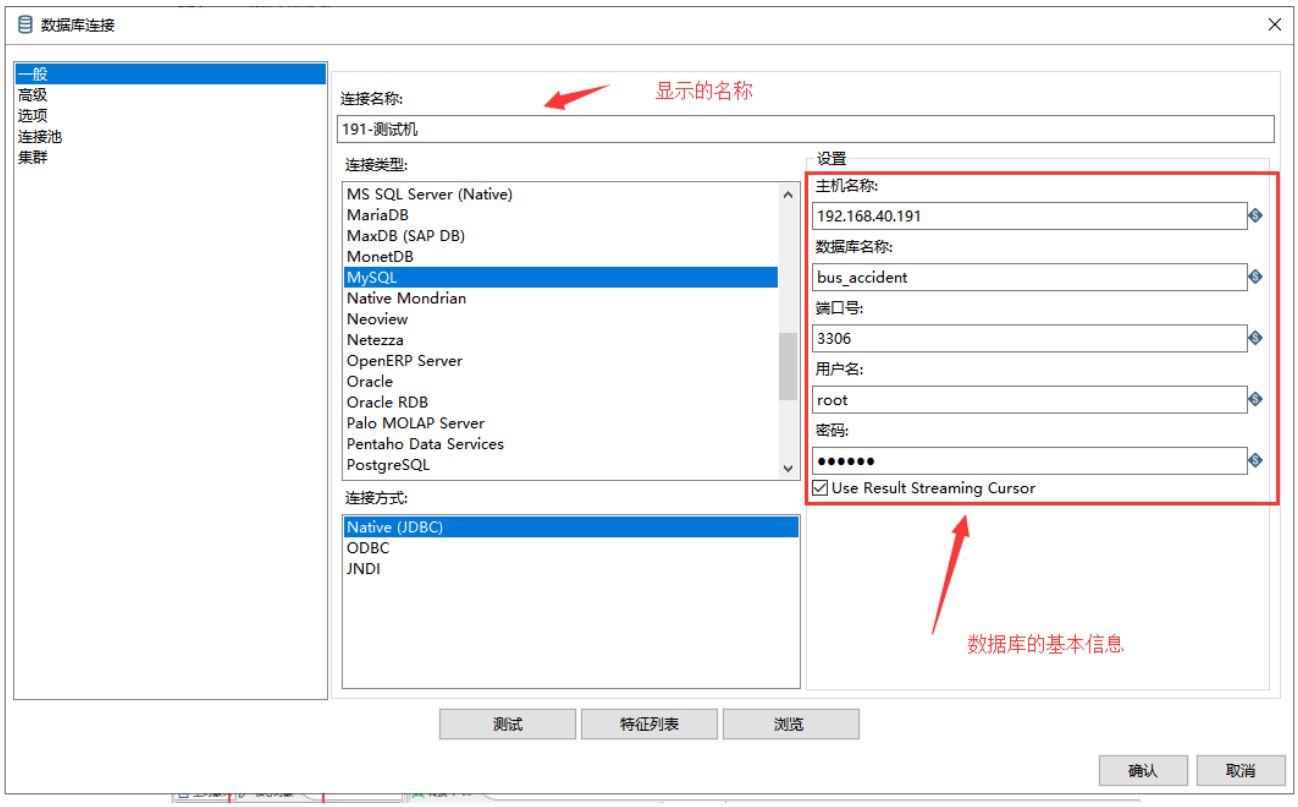

需要注意的是图上的所有信息都必须填写完整，若没有填写完它是不会让你确认的，填写完后点 `测试` ，若能正确连接再确认

> 连接成功后，可能会出现写入数据出现乱码问题，这时候可以在被写入数据库连接中点击高级，设置连接参数 characterEncoding 为 utf8

我们需要从本机库同步数据到测试服务器，所以我们还需要添加本地连接进去，最后效果图

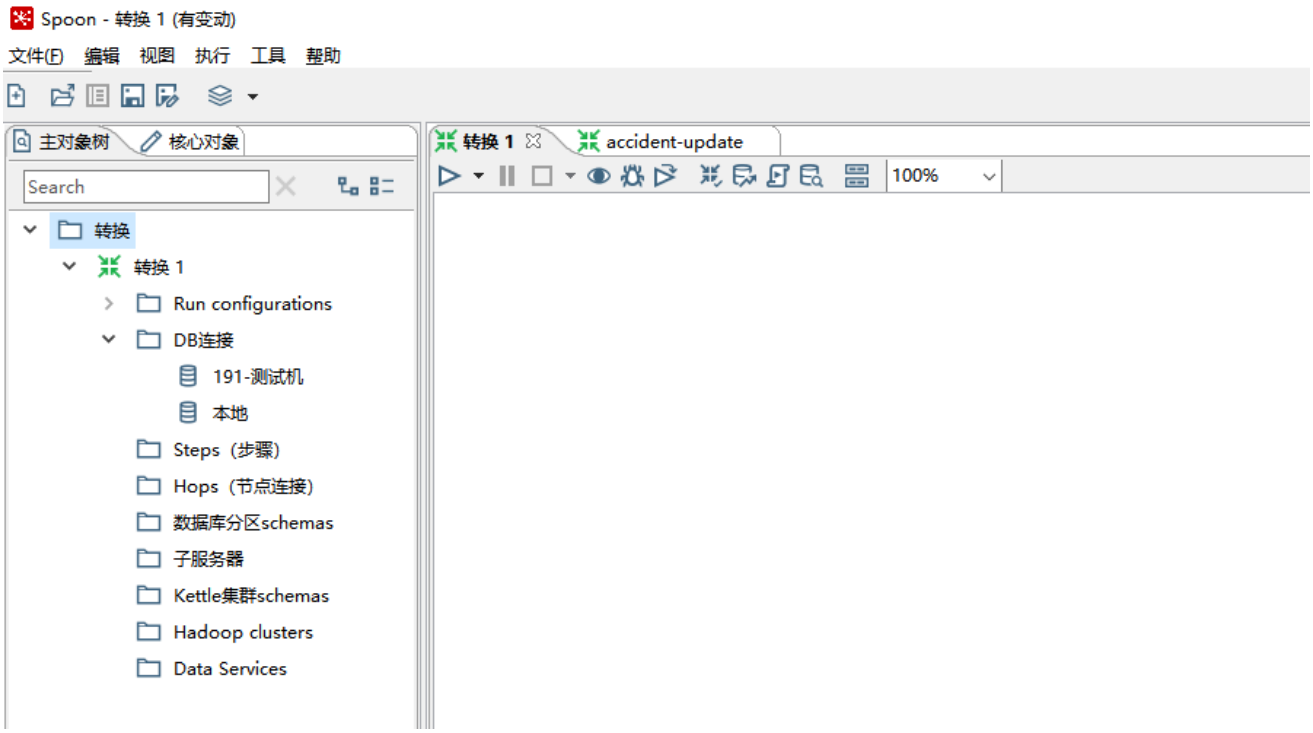

从数据源中获取数据

在 核心对象 里面点击 输入 下拉框，找到表输入

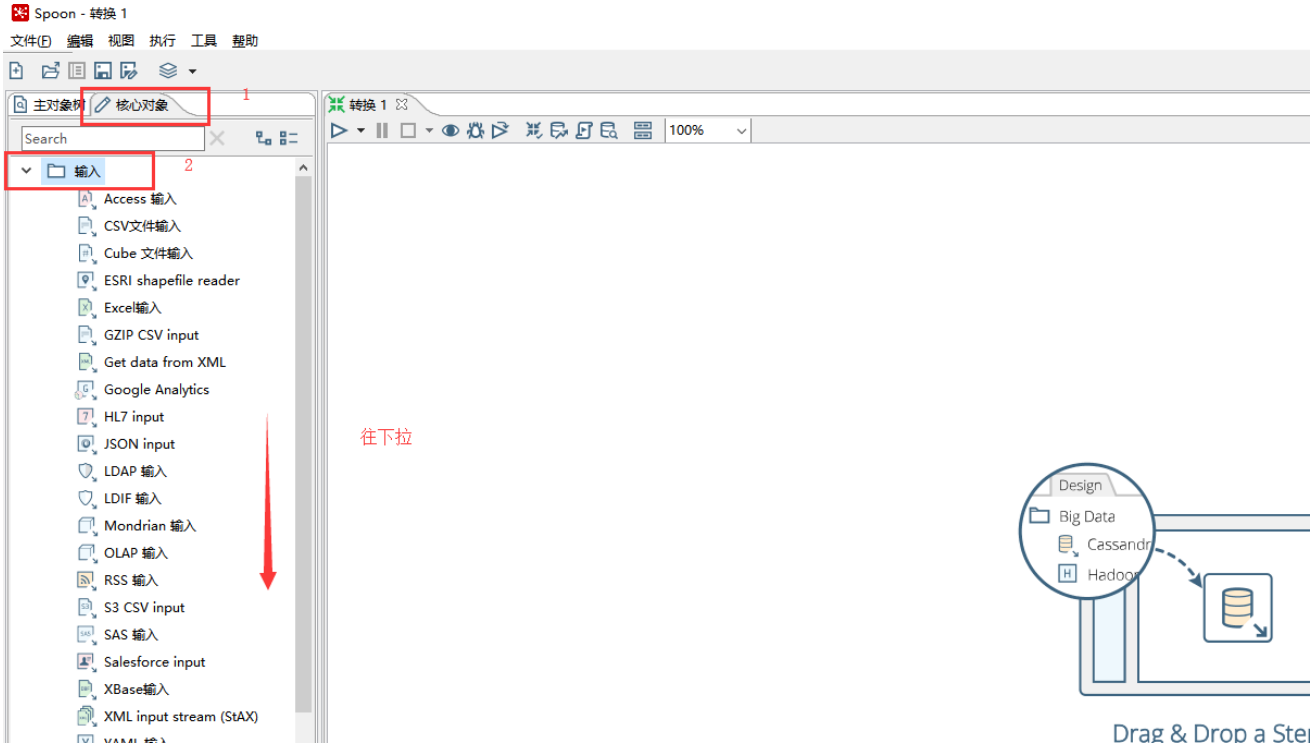

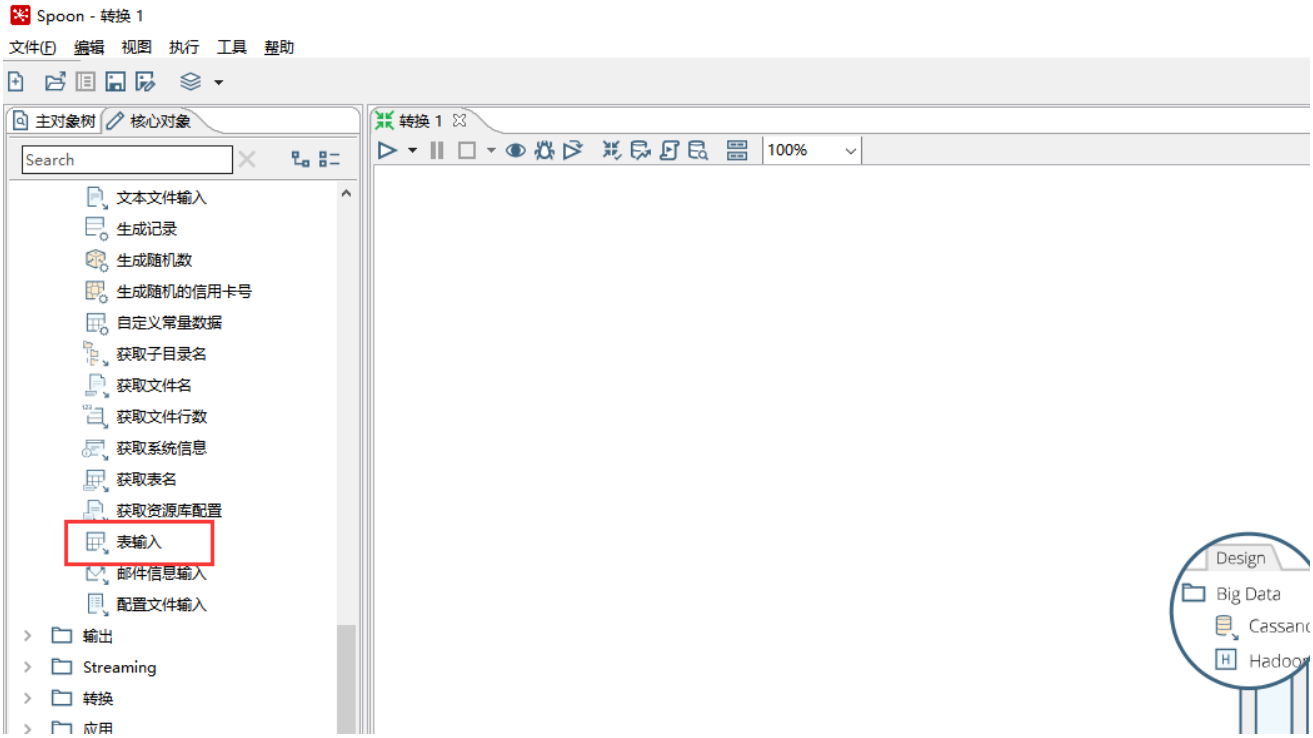

双击它后我们会在右边的大框框里看到一个表输入，双击后可以配置他

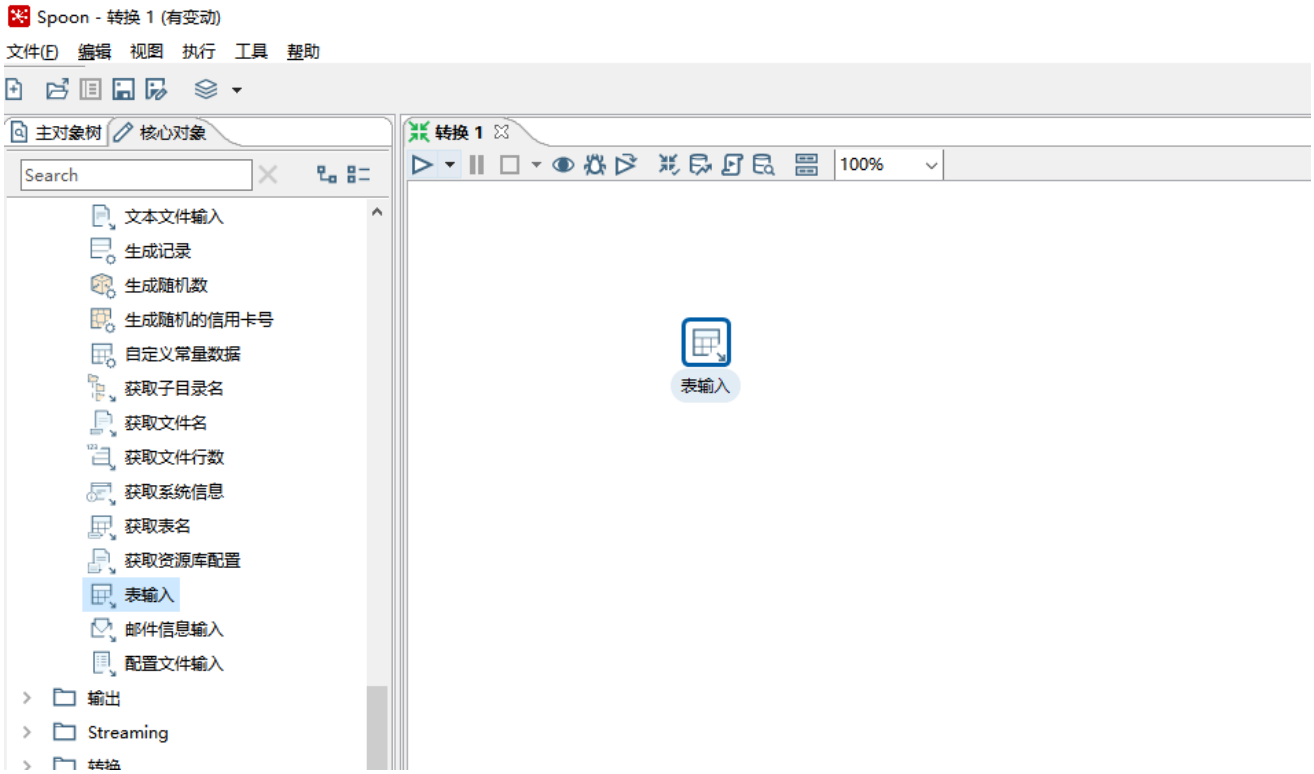

看一下我配置过的一个例子

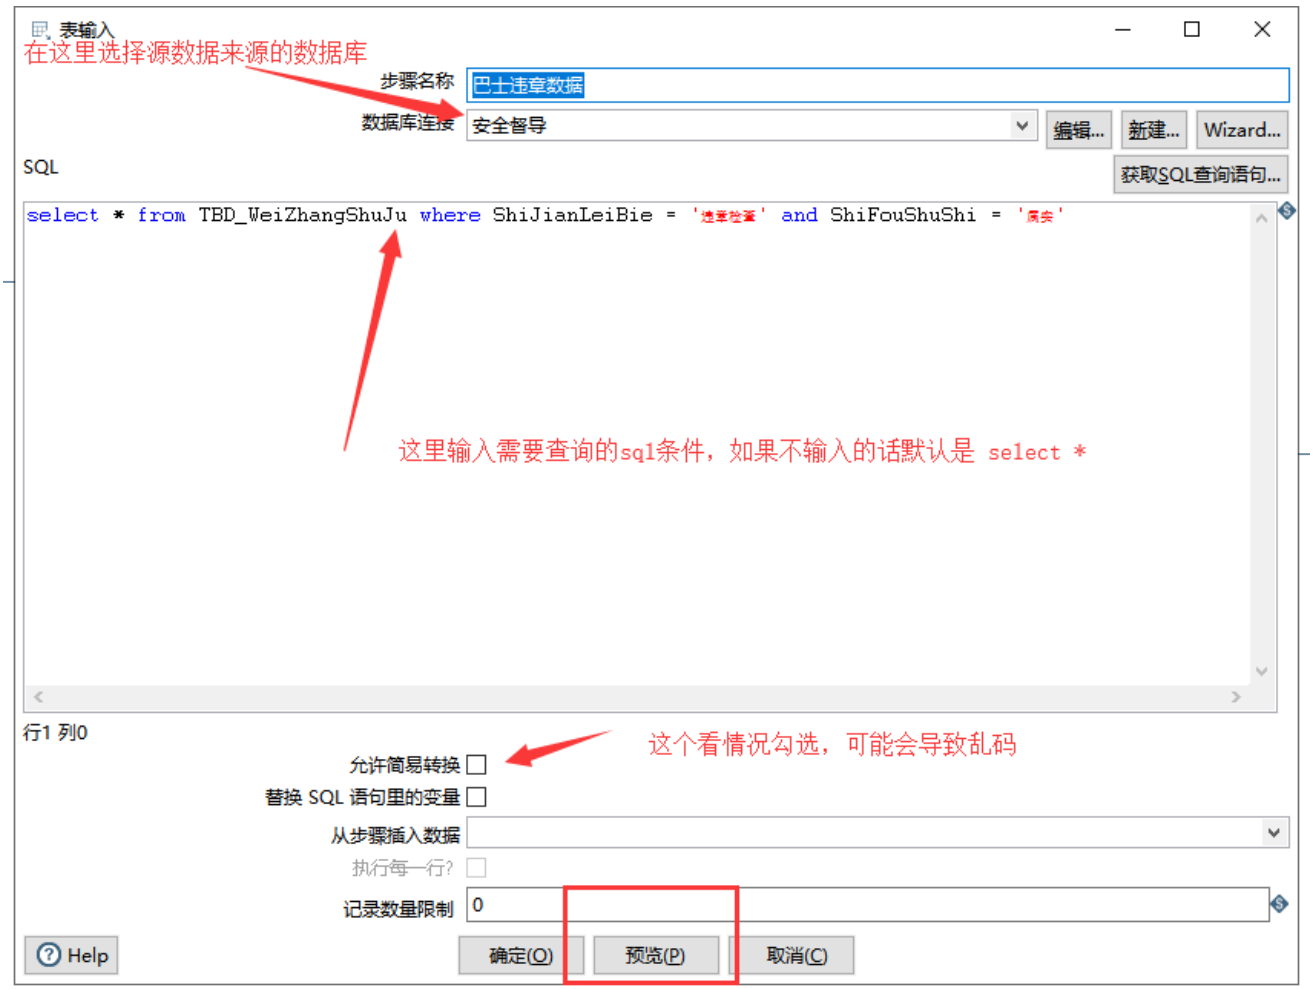

需要注意的有3点：

- 数据库选择不要选择错了，表输入中的数据库选择是源数据的数据库
- 中间的大 SQL 框可以不修改，默认是抓取全部数据，也可以点击 `获取SQL查询语句` 来生成 `SQL`
- 允许建议转换这个选项，网上有教程说需要勾选，不然会导致乱码，我测试的情况是勾了之后反而导致了乱码，具体需要看使用情况而定

配置好后点击 `预览` 按钮，若可以查询出数据则代表配置成功

这样，获取源数据就完成了

将获取的源数据保存起来

在 `核心对象` 中，除了有输入外，还有输出，我们先看一下输出列表中有哪些选项，他们有什么不一样

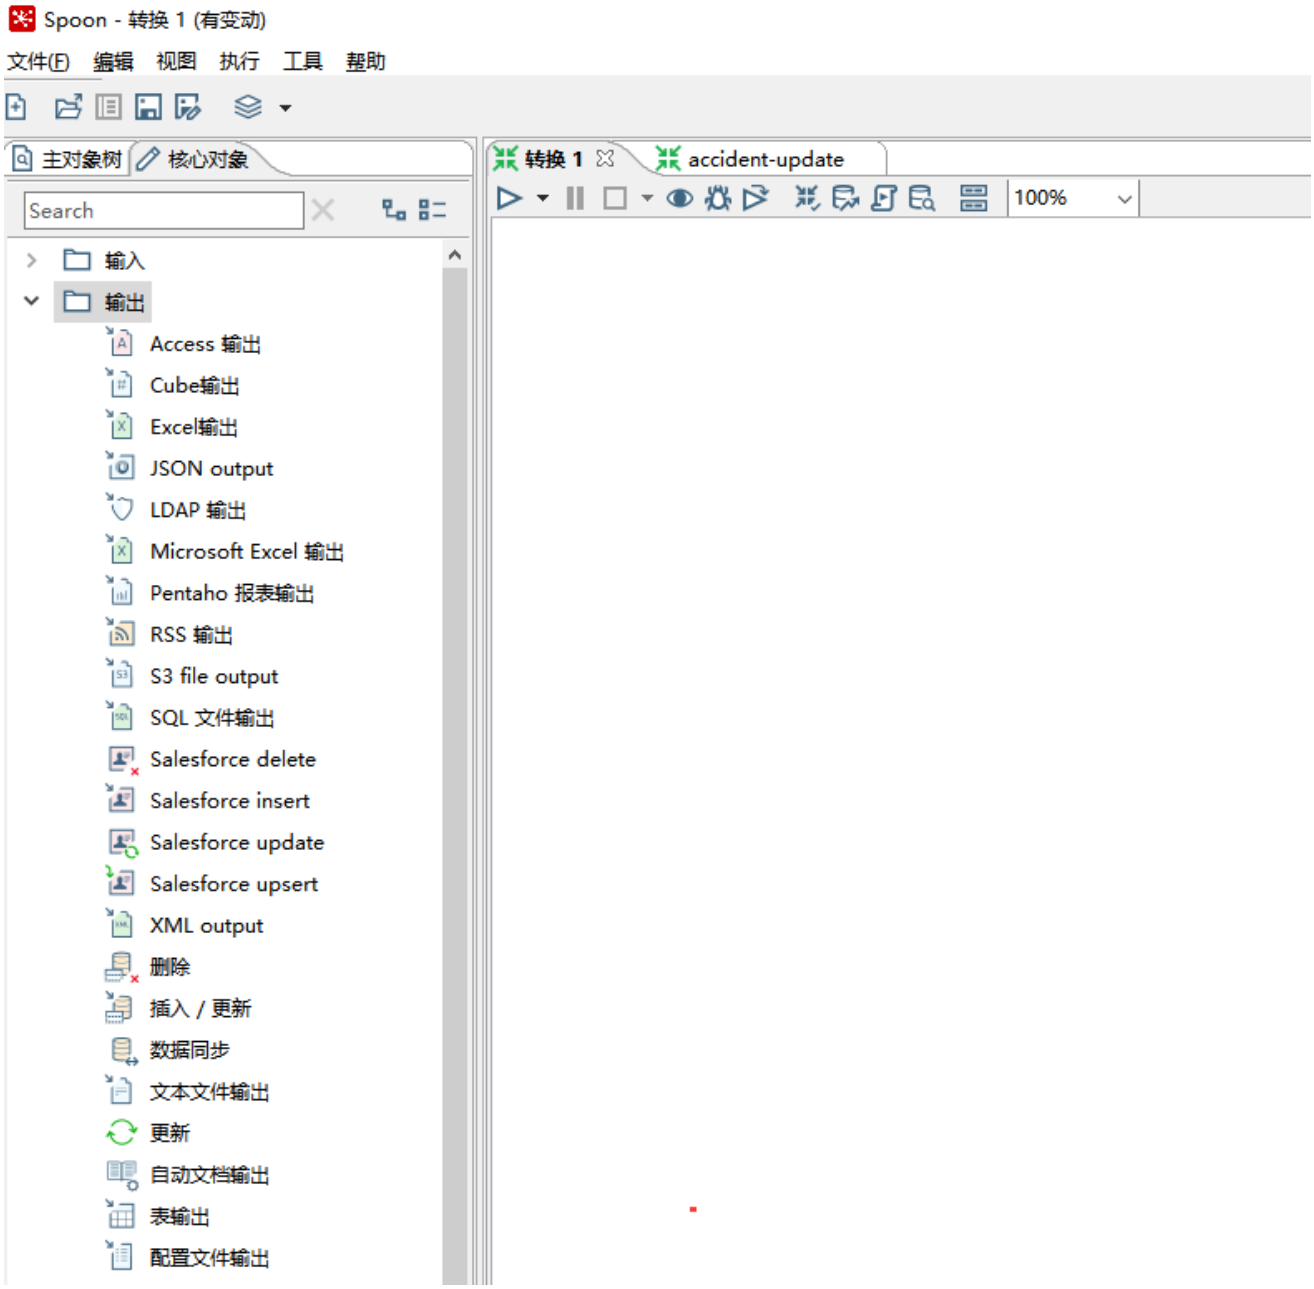

emm，一大堆看不懂的东西

我们都不要管它，表输出？是把刚获取的表输入直接整个输出出去，适合一次性使用的导表功能。

我们只要看 `插入/更新` 如果你需要删除的话，那就再看多一个 `删除` 吧

输出栏里还有一个 `数据同步` 选项，这个点进去会发现和 `插入/更新` 很像，具体的区别在哪，我查文档也没发现，这里我们也用不上

配置插入/更新

我们将一个插入更新拖到中间的版版中，双击看一下

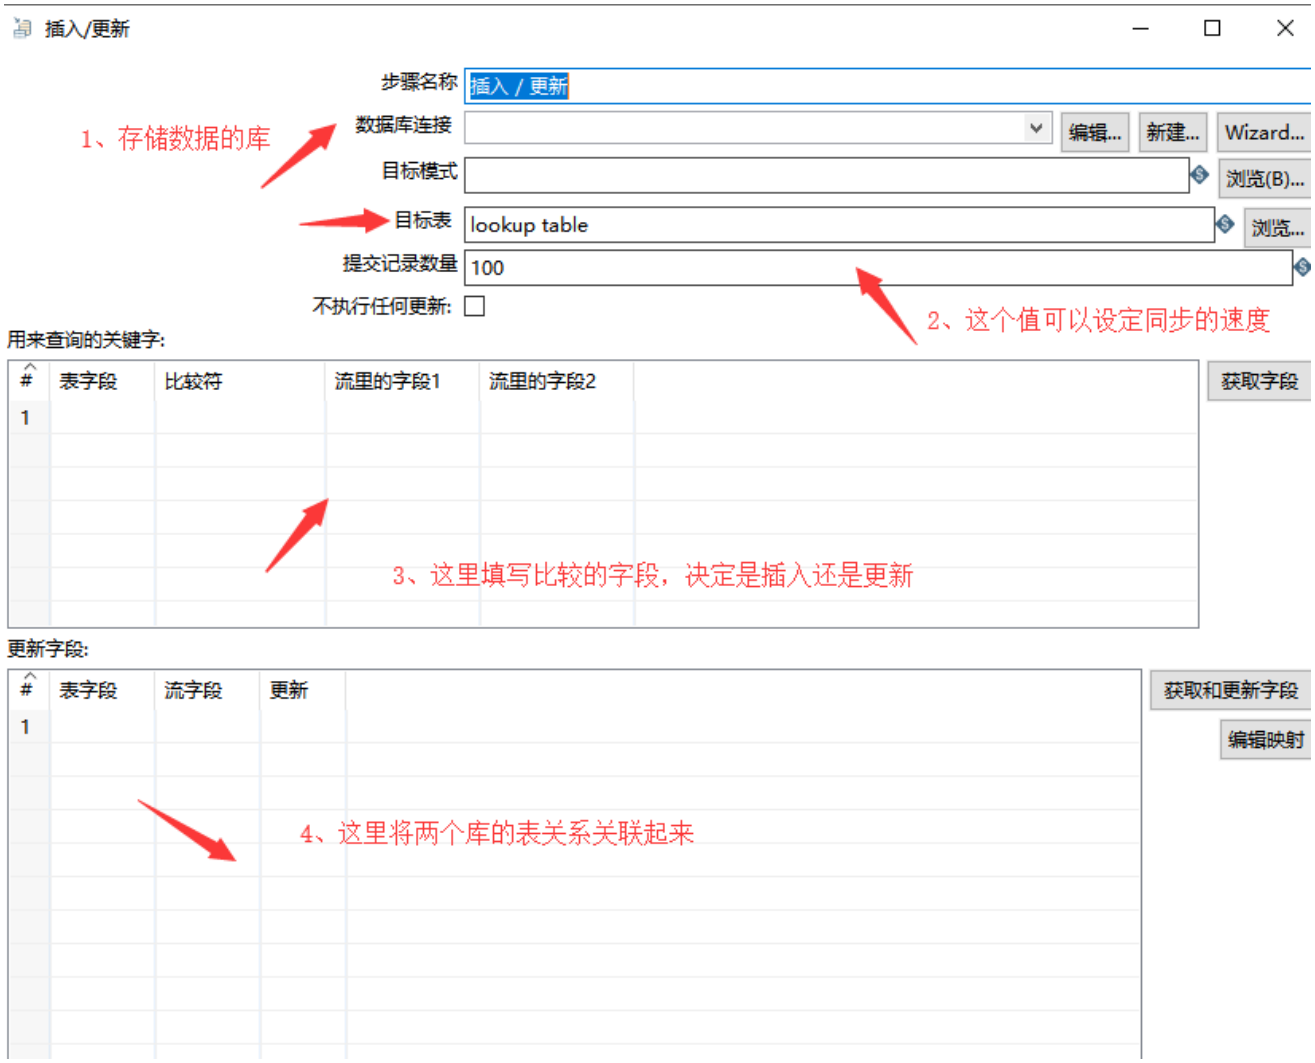

主要有4点内容，其中第四点是最麻烦的

- 先设置目标数据库与目标表，目标表需要在设置了目标数据库后点击浏览选择
- 提交记录量，这个值如果设置的太小就会造成多次插入，太大会担心连接中断
- 第三点是设置用来比较的字段，例如 ID，当 ID 存在的时候就更新，不存在的时候就插入
- 第四点是最复杂的一点，因为目标数据表可以和源数据表字段不一样，可以改名，改大小写，所以这里需要人工一一对应，感觉整个工作量都在这里了。

注意，有一个很关键的点！若是直接把这个控件拖到了白板中，那么他是和前面设定的 `表输入` 没有关联起来的，看有么有关联起来，就要看他们之间是否有一条箭头连线，若没有连线，在 `插入/更新` 中是无法匹配上字段的

附上一张完整的图

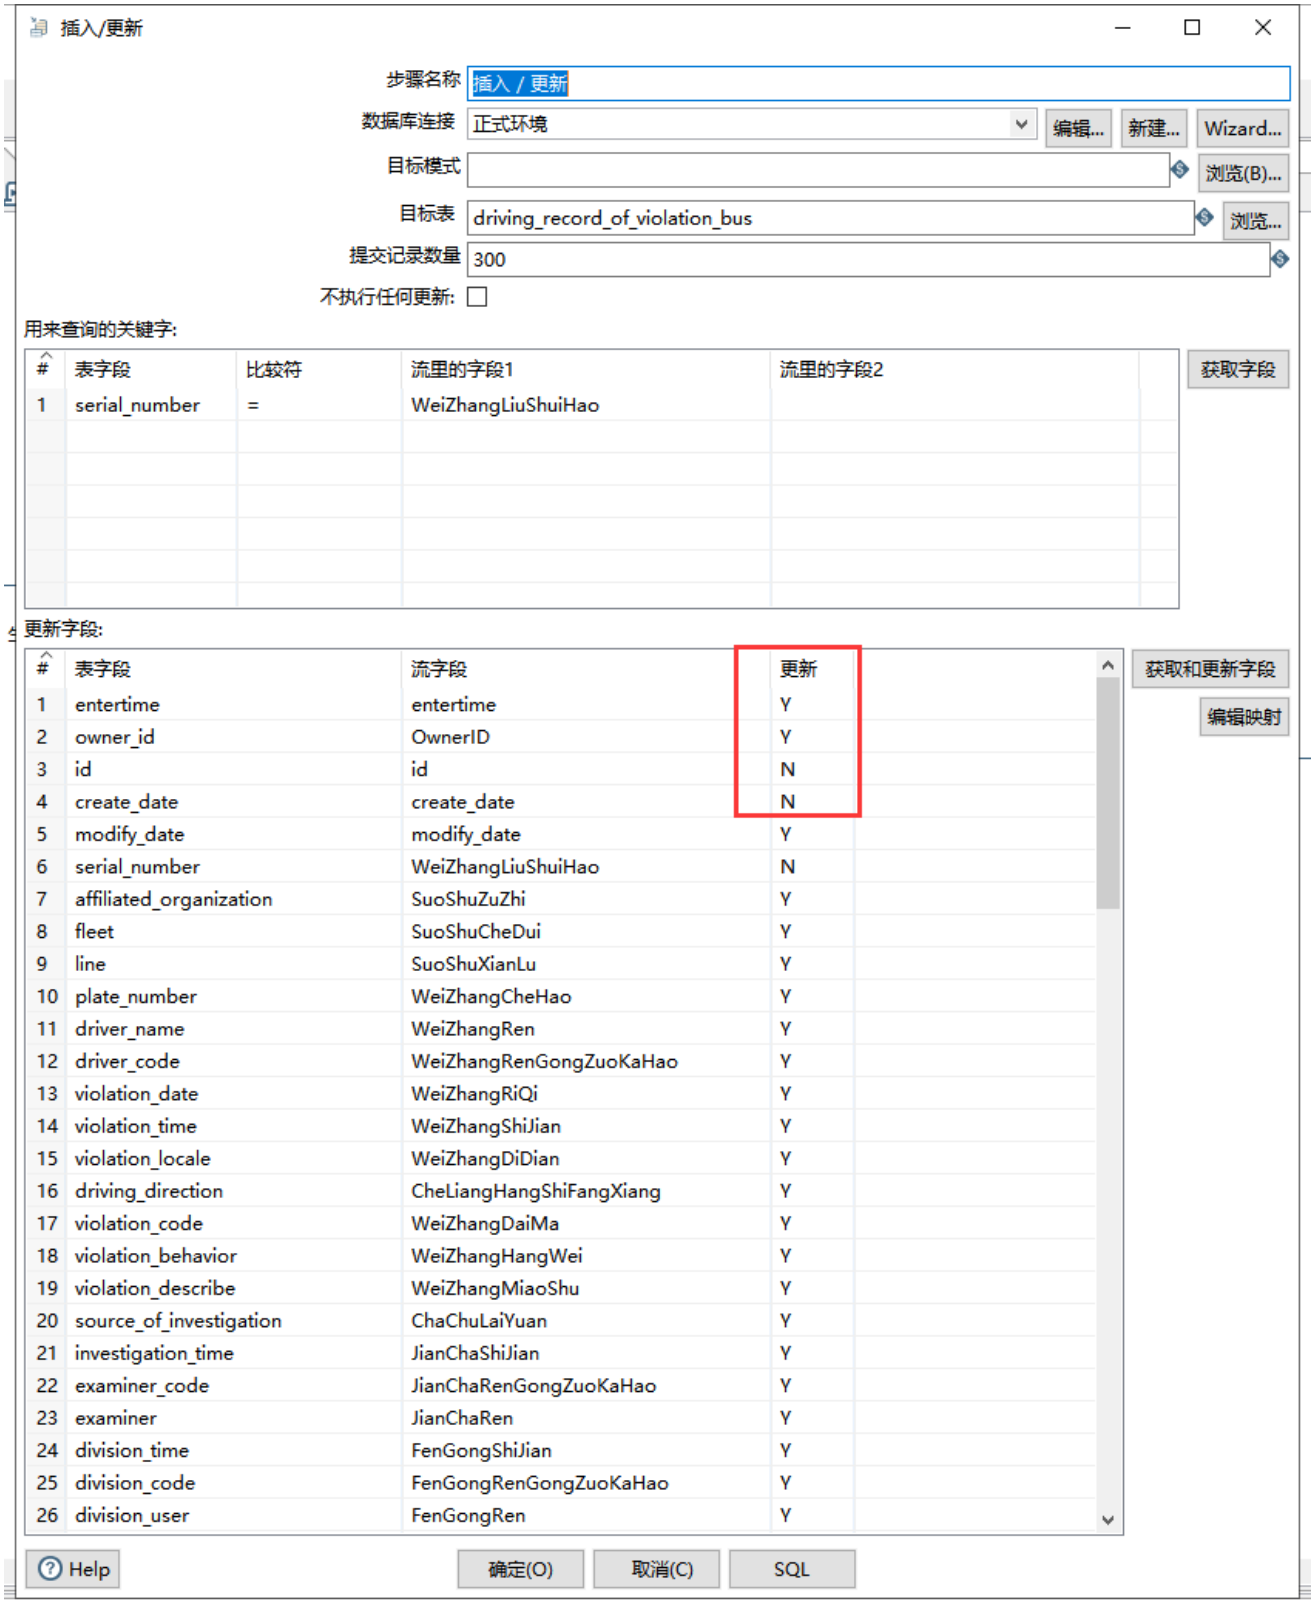

> 图中被我红圈圈起来的是标注该字段是否更新（这样子对那些接过来的数据又可以改的很友好啊）

下一步该干嘛

当我们设置好了输入输出后，来看一下大框框有了什么

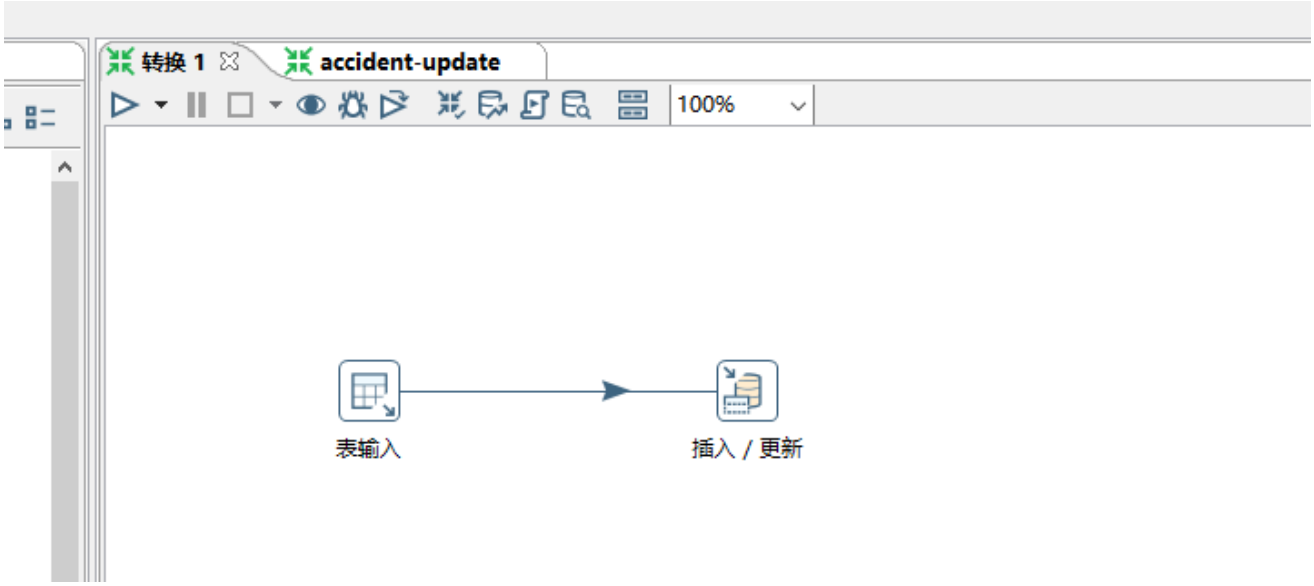

这样的时候已经是可以启动转换的了！不过我们好像，还漏了点什么

需要另外设置 ID 要怎么办?

我们获取数据转换的时候，可以将 ID 设置为跟源数据一样的，这时候只要设置转换就好了，那么我们想配置新的 ID 呢，或者说源数据里面用了某个很蠢的字段做了主键，我们想生成一个 UUID 怎么办?

我们回过头看一下 `输入` 里面有一个 `生成随机数` ，双击一下

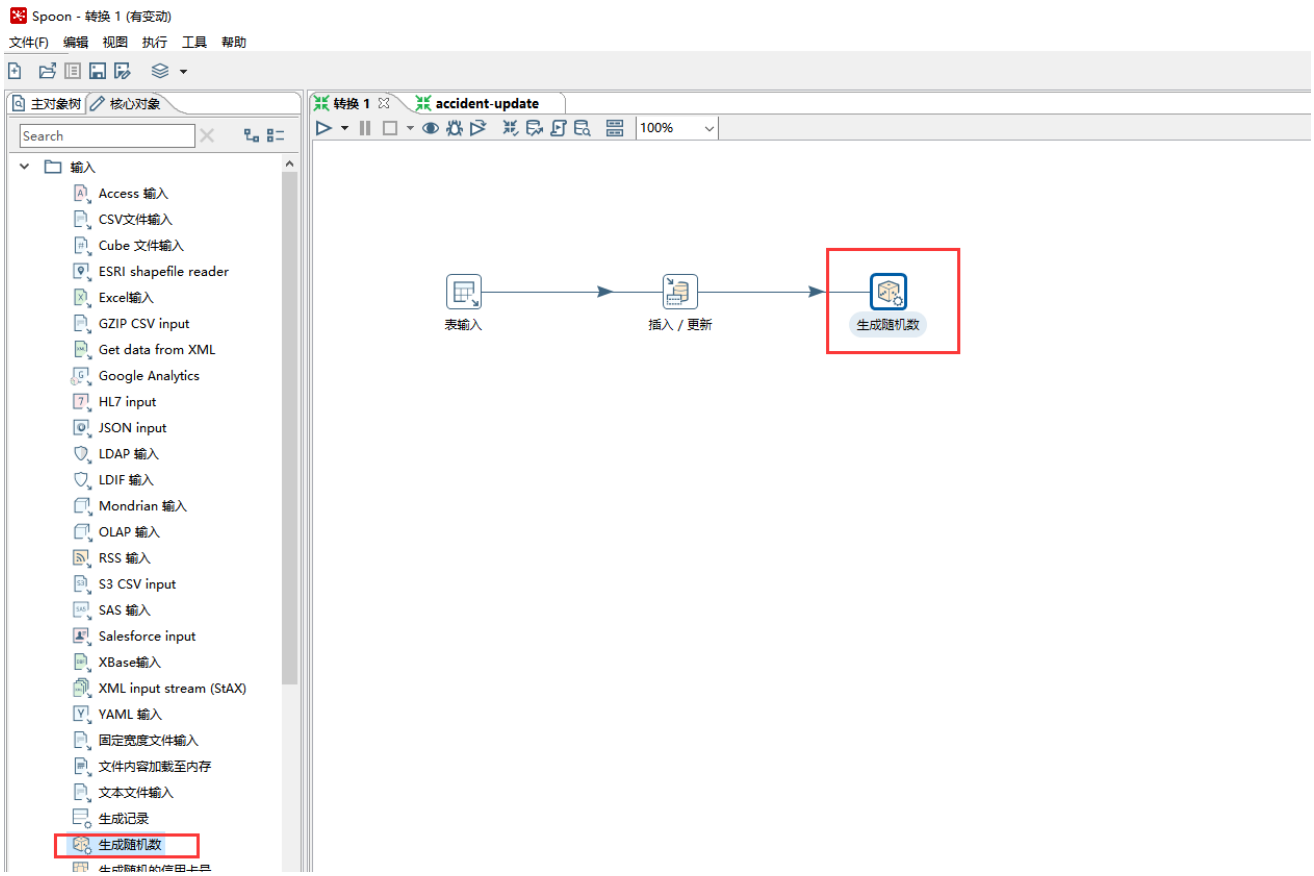

就是这个玩意，我们打开设置一下

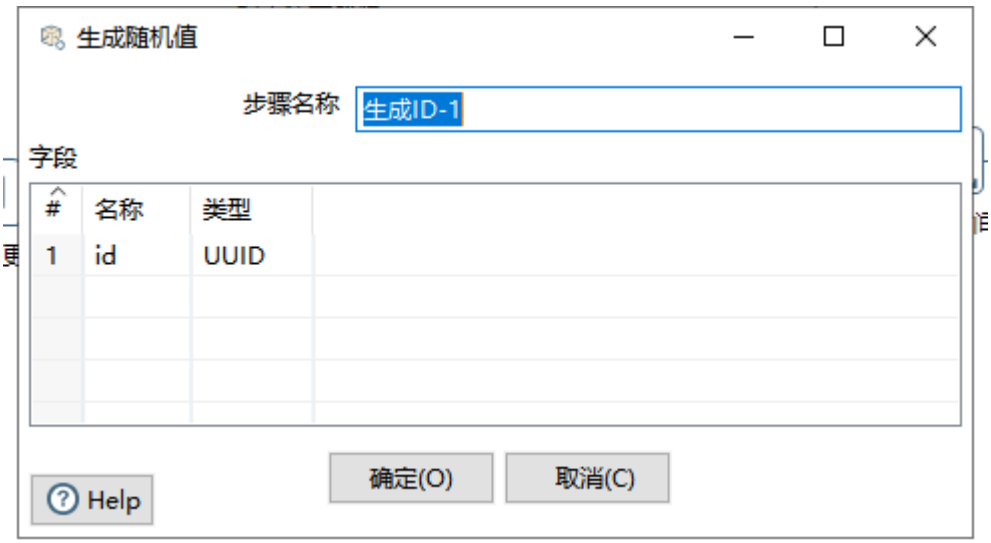

因为都是 `输入` 选项，所以需要调整一下它的位置

> 创建连接线条是点击源组件 按着 shift 键，然后拉过去就好了

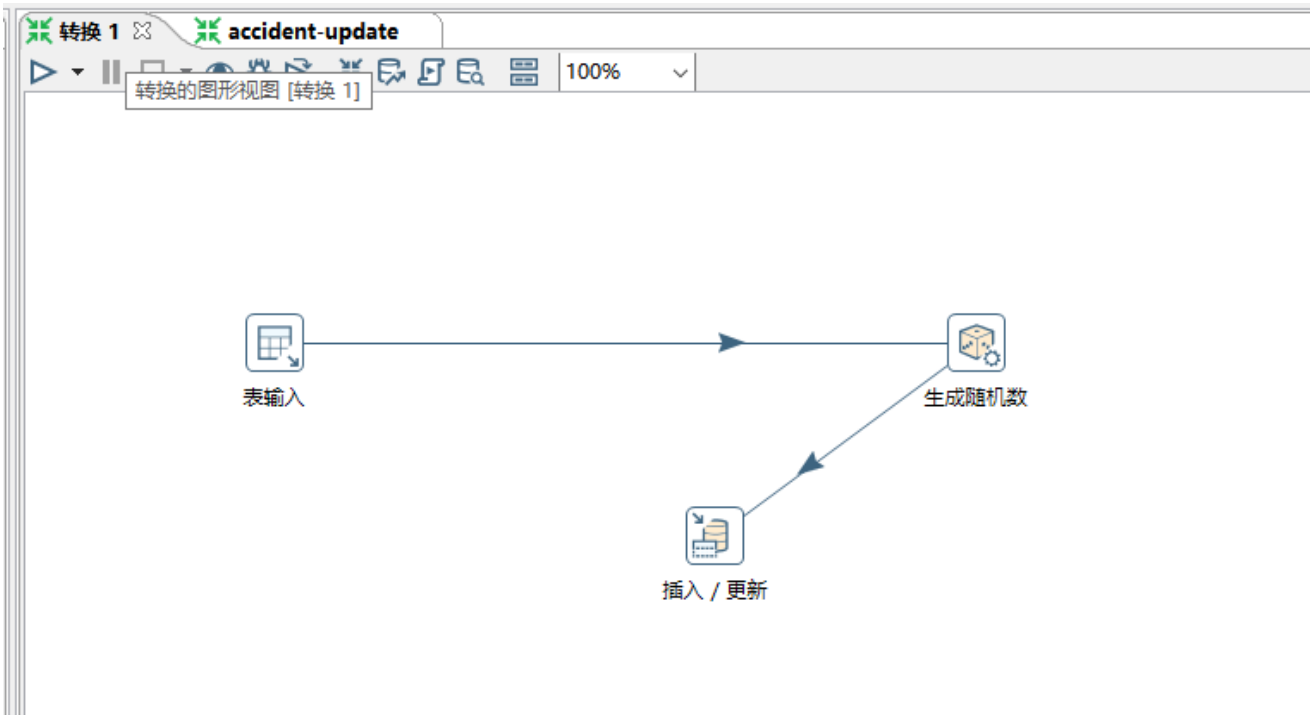

大功告成!

好像还是漏了点什么

按照 sibat 的编程习惯，每条数据都是由 `create_day` 和 `modify_date` 的，而数据源中不一定会有，刚面一个讲到的是一个随机数，那么时间怎么添加?

还有一个组件，也是在 `输入` 里面的 `获取系统信息`

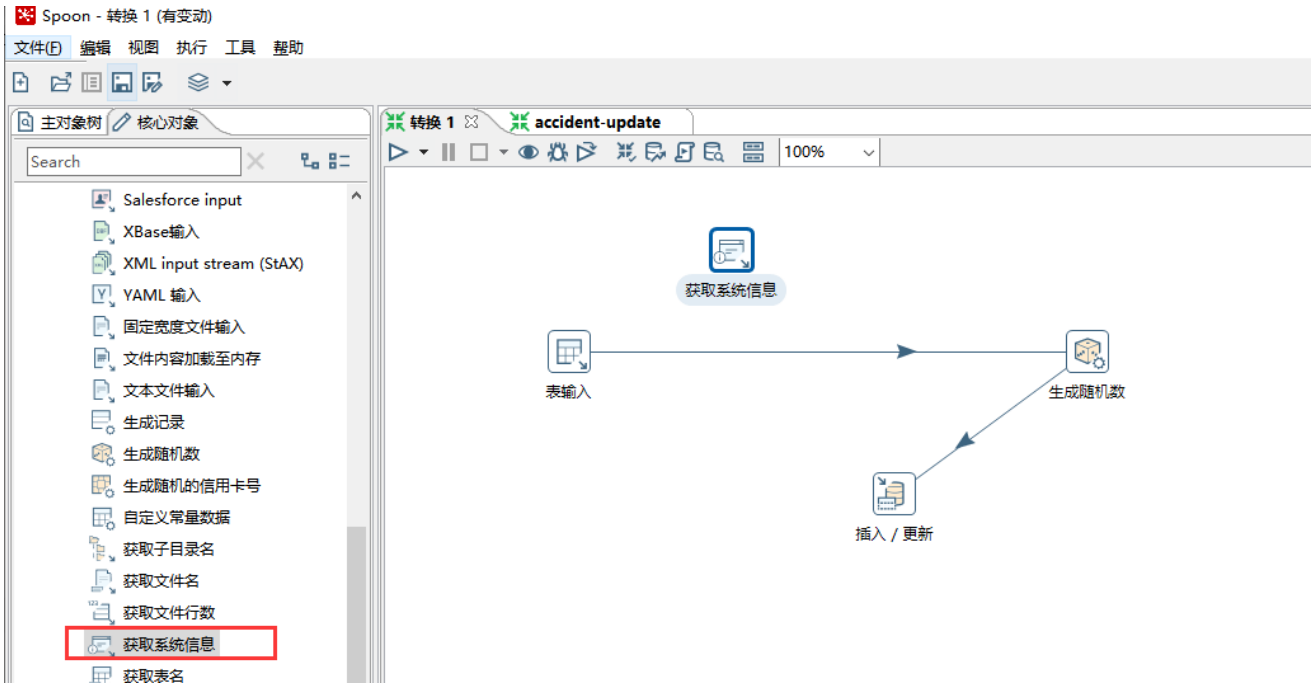

我们来配置一下

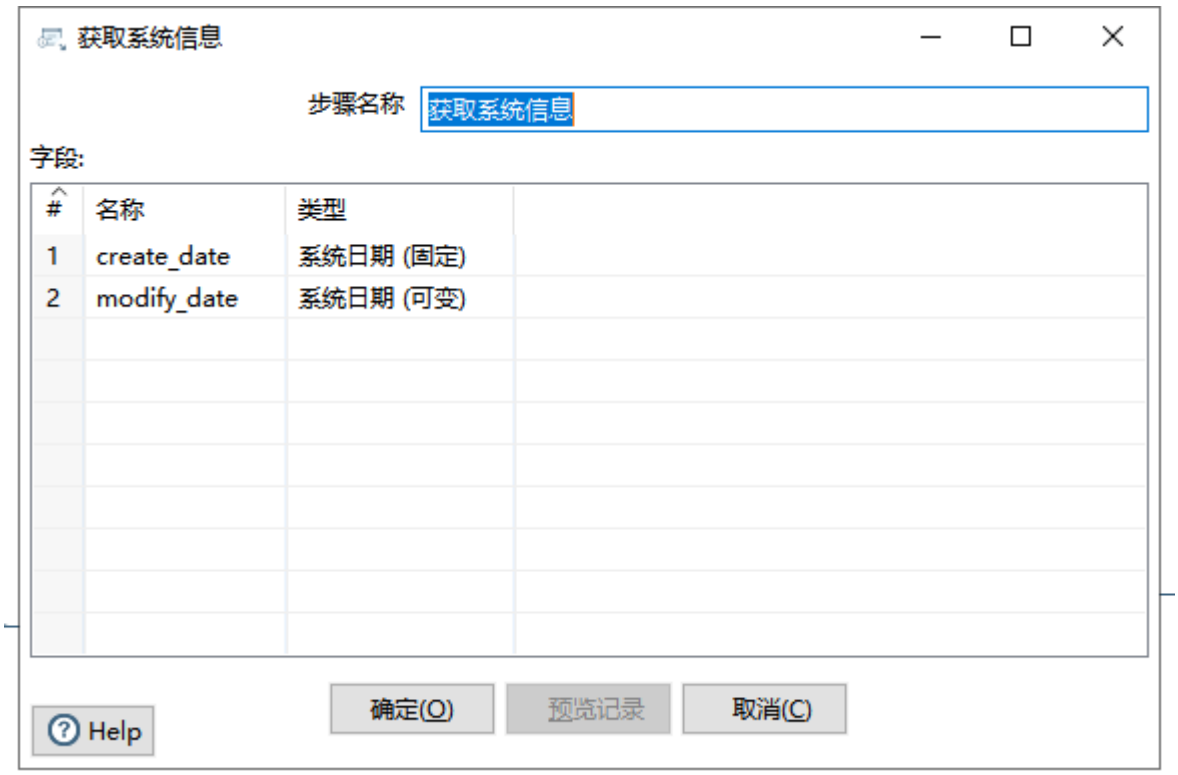

然后再调整一下顺序

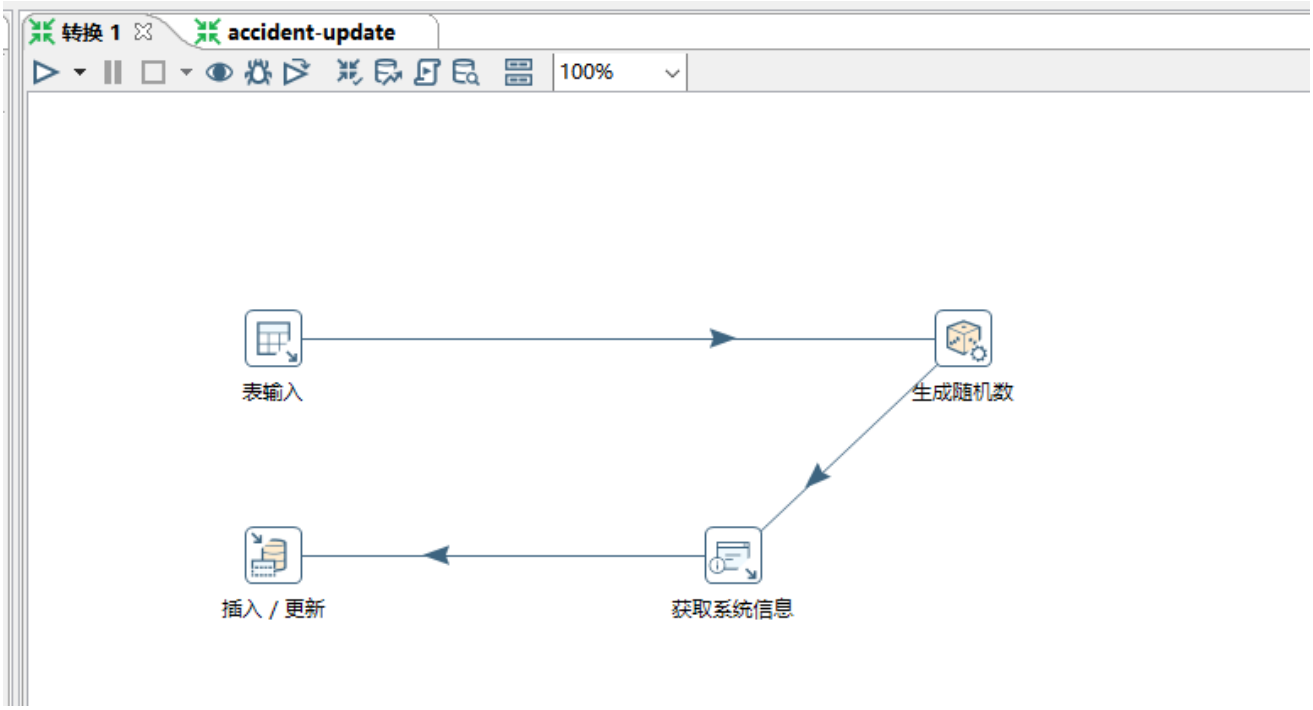

这样，符合我们的一个转换流程就弄好了！

贴出一张正在运行的图

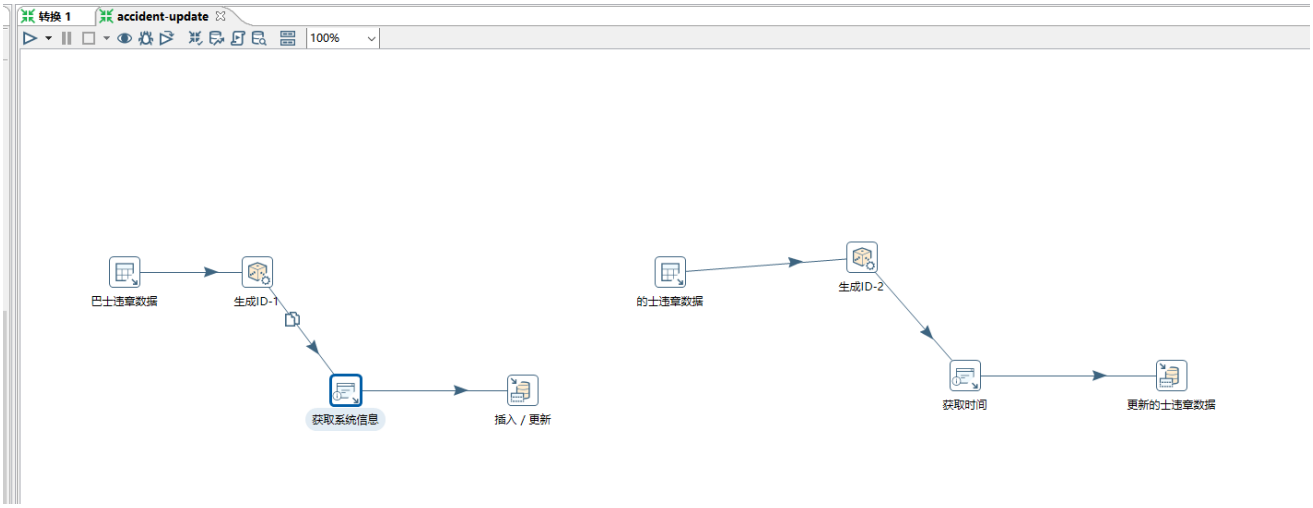

图中我们可以看出，多个转换可以放在一个面板了，他们是并发的

如何部署到 linux 并设置定时器

先把我们的软件包传到 linux 下，整个包，1点多G

上面我们讲到，在 `windows` 下，我们启动的是 `Spoon.bat` ，在 `linux` 中，我们需要用到做定时任务的，不需要打开它的图形界面，要用到的指令是 `pan.sh`

我们将我们在 `windows` 下创建好的转换任务也上传到 `linux` 中，他的后缀名是 `.ktr` 文件

编写转换脚本

`kettle` 的转换需要用到 `JDK` 环境，所以 `linux` 需事先装好 `JDK` 并且记住他的环境变量

看一下我们的脚本

```
export JAVA_HOME=/usr/local/java/jdk1.8.0_181
export JRE_HOME=/usr/local/java/jdk1.8.0_181/jre
export CLASSPATH=.:$JAVA_HOME/lib:$JRE_HOME/lib:$CLASSPATH
# 这里开始时 kettle 的脚本，指定他的 pan.sh 目录
export PATH=$JAVA_HOME/bin:$JRE_HOME/bin:$PATH
/usr/local/tools/data-integration/pan.sh -file=/opt/kettle/ktr/转换.ktr >
/opt/kettle/ktr/log.log
```

然后将其放入定时器中

在 `linux` 下输入 `crontab -e` 查看定时任务 然后添加刚编写的 `shell` 脚本就好（这部分不会的童鞋百度去）

可能会出现的问题

下载的 `kettle` 可能会没有 `mysql jdbc` 的连接驱动包，需要手动下载放入安装目录的 `lib` 下，我使用的版本就没有